



UNIVERSIDADE FEDERAL DE GOIÁS
Instituto de Informática
Especialização em Residência em Tecnologia da Informação

Geyson de Araújo Sousa

**MODELAGEM ANALÍTICA E APRENDIZADO DE MÁQUINA
PARA TRIAGEM DE OCORRÊNCIAS POTENCIALMENTE
ATÍPICAS NO SISTEMA EXTRAJUDICIAL ELETRÔNICO DO
TJGO: UMA PROVA DE CONCEITO**

Trabalho de Conclusão de Curso

Goiânia
2026

UNIVERSIDADE FEDERAL DE GOIÁS
Instituto de Informática
Especialização em Residência em Tecnologia da Informação

Geyson de Araújo Sousa

**MODELAGEM ANALÍTICA E APRENDIZADO DE MÁQUINA
PARA TRIAGEM DE OCORRÊNCIAS POTENCIALMENTE
ATÍPICAS NO SISTEMA EXTRAJUDICIAL ELETRÔNICO DO
TJGO: UMA PROVA DE CONCEITO**

Trabalho de Conclusão de Curso apresentado ao Programa de Pós-Graduação Lato Sensu Especialização em Residência em Tecnologia da Informação do Instituto de Informática da Universidade Federal de Goiás, como requisito parcial para obtenção do título de Especialista em Residência em Tecnologia da Informação.

Orientadores: Deborah Silva
Márcio Giovane C. Fernandes

Goiânia
2026

UNIVERSIDADE FEDERAL DE GOIÁS
Instituto de Informática
Especialização em Residência em Tecnologia da Informação

Geyson de Araújo Sousa

**MODELAGEM ANALÍTICA E APRENDIZADO DE MÁQUINA PARA
TRIAGEM DE OCORRÊNCIAS POTENCIALMENTE ATÍPICAS NO
SISTEMA EXTRAJUDICIAL ELETRÔNICO DO TJGO: UMA PROVA DE
CONCEITO**

Trabalho de Conclusão de Curso apresentado ao Programa de Pós-Graduação Lato Sensu
Especialização em Residência em Tecnologia da Informação do Instituto de Informática da
Universidade Federal de Goiás.

Aprovado por:

Orientadores:

Deborah Silva

Márcio Giovane C. Fernandes

Examinador Interno 1:

Eduardo Albuquerque

Examinador Interno 2:

Nivaldo Moraes

Data: ____/____/____

RESUMO

O Sistema Extrajudicial Eletrônico (SEE) do Tribunal de Justiça do Estado de Goiás (TJGO) reúne grande volume de registros transacionais que podem apoiar abordagens analíticas de triagem. Este trabalho apresenta uma Prova de Conceito (PoC) para identificar e priorizar ocorrências potencialmente atípicas, combinando segmentação por porte operacional com K-Means, afastamento relativo por Z-Score e detecção não supervisionada por Isolation Forest. A base foi agregada na unidade Serventia $\times$ Mês e compreende janeiro de 2016 a julho de 2025. Após o recorte temporal e o saneamento, foram analisadas 57.480 observações referentes a 524 serventias. O campo `guia_id` foi excluído da modelagem por não sustentar interpretação financeira confiável. A arquitetura híbrida selecionou 790 ocorrências (1,37% da base), enquanto uma linha de base baseada em percentis globais selecionou 8.166 (14,21%), representando redução de aproximadamente 90,3% no universo priorizado. Dos 790 alertas, 377 resultaram da convergência entre Z-Score elevado e classificação anômala pelo Isolation Forest, 349 foram classificados como alertas moderados e 64 como alertas multivariados. Os resultados sustentam maior seletividade, contextualização por porte e rastreabilidade da PoC em relação à baseline, mas não permitem afirmar maior precisão, relevância correcional ou identificação de irregularidades, pois o estudo não dispõe de ground truth nem de validação humana dos alertas. A contribuição do trabalho consiste em uma arquitetura auditável e reproduzível, acompanhada de pipeline analítico e painéis gerenciais, preparada para posterior validação institucional antes de eventual uso operacional.

Palavras-chave: detecção de anomalias; triagem analítica; K-Means; Isolation Forest; Z-Score; Sistema Extrajudicial Eletrônico.

ABSTRACT

The Electronic Extrajudicial System (SEE) of the Court of Justice of the State of Goiás (TJGO) contains a large volume of transactional records that can support analytical screening approaches. This study presents a Proof of Concept (PoC) to identify and prioritize potentially atypical occurrences by combining operational-size segmentation with K-Means, relative deviation measured by Z-Score, and unsupervised detection using Isolation Forest. The database was aggregated at the Registry Office $\times$ Month level and covers the period from January 2016 to July 2025. After temporal filtering and data cleaning, 57,480 observations referring to 524 registry offices were analyzed. The `guia_id` field was excluded from the modeling because it did not support a reliable financial interpretation. The hybrid architecture selected 790 occurrences (1.37% of the database), while a baseline based on global percentiles selected 8,166 (14.21%), representing a reduction of approximately 90.3% in the prioritized universe. Among the 790 alerts, 377 resulted from the convergence between a high Z-Score and an anomalous classification by Isolation Forest, 349 were classified as moderate alerts, and 64 as multivariate alerts. The results support greater selectivity, operational-size contextualization, and traceability of the PoC compared with the baseline, but do not allow claims of greater precision, correctional relevance, or identification of irregularities, since the study has neither ground truth nor human validation of the alerts. The contribution of the study is an auditable and reproducible architecture, accompanied by an analytical pipeline and management dashboards, prepared for subsequent institutional validation before any possible operational use.

Keywords: anomaly detection; analytical screening; K-Means; Isolation Forest; Z-Score; Electronic Extrajudicial System.

LISTA DE TABELAS

3.1	Caracterização do universo analítico	10
3.2	Variáveis centrais da Prova de Conceito	11
4.1	Métricas utilizadas na seleção do número de faixas de porte	13
4.2	Caracterização das quatro faixas de porte operacional	13
4.3	Seletividade das estratégias analíticas	14
4.4	Distribuição dos alertas da arquitetura híbrida	15
4.5	Sensibilidade ao parâmetro contamination	15

LISTA DE FIGURAS

- 4.1 Distribuição das observações segundo as faixas de porte operacional. A taxa exibida no eixo vertical possui função descritiva; a formação das faixas pelo K-Means utilizou exclusivamente log_total_selos. 14
- 4.2 Painel gerencial desenvolvido para exploração dos resultados da Prova de Conceito. 16

LISTA DE ABREVIATURAS E SÍMBOLOS

ABREVIATURAS

SEE	Sistema Extrajudicial Eletrônico
TJGO	Tribunal de Justiça do Estado de Goiás
PoC	Prova de Conceito
CRISP-DM	Cross-Industry Standard Process for Data Mining
IF	Isolation Forest

SUMÁRIO

RESUMO	2
ABSTRACT	3
LISTA DE TABELAS	4
LISTA DE FIGURAS	5
LISTA DE ABREVIATURAS E SÍMBOLOS	6
SUMÁRIO	7
1 INTRODUÇÃO	8
2 FUNDAMENTAÇÃO ESSENCIAL	9
2.1 Ciência de dados e apoio analítico no setor público	9
2.2 Fiscalização orientada a dados	9
2.3 CRISP-DM e técnicas empregadas	9
3 MÉTODO	10
3.1 Desenho do estudo e base de dados	10
3.2 Qualidade dos dados e engenharia de variáveis	10
3.3 Arquitetura analítica e baseline	11
3.4 Estratégia de avaliação	12
4 RESULTADOS	13
4.1 Segmentação por porte operacional	13
4.2 Seletividade da arquitetura híbrida	14
4.3 Sensibilidade e estabilidade	15
4.4 Produtos da Prova de Conceito	15
5 DISCUSSÃO	17
6 LIMITAÇÕES E GOVERNANÇA	19
7 CONCLUSÃO	20
REFERÊNCIAS BIBLIOGRÁFICAS	21

1 INTRODUÇÃO

A digitalização dos serviços públicos ampliou a disponibilidade de registros transacionais e criou novas possibilidades para o uso de análise de dados em atividades de controle. Na fiscalização extrajudicial, procedimentos baseados em inspeções pontuais, amostragem e consultas reativas continuam relevantes, mas podem ser complementados por mecanismos capazes de examinar grandes volumes de dados de forma sistemática (ARENS; ELDER; BEASLEY, 2014; SILVA, 2012).

No Tribunal de Justiça do Estado de Goiás (TJGO), o Sistema Extrajudicial Eletrônico (SEE) concentra informações sobre a utilização de selos pelas serventias. A existência dessa série histórica permite construir indicadores, comparar comportamentos operacionais e selecionar ocorrências que mereçam análise posterior. A proposta é coerente com a Estratégia Nacional de Tecnologia da Informação e Comunicação do Poder Judiciário (ENTIC-JUD), estabelecida pela Resolução CNJ nº 370/2021, e com iniciativas de Business Intelligence já empregadas no próprio TJGO (BRASIL, 2021; BONTEMPO et al., 2024).

O desafio analítico não é apenas identificar valores elevados. Serventias possuem portes operacionais muito diferentes, e regras globais aplicadas ao volume absoluto podem privilegiar unidades maiores. Além disso, uma ocorrência estatisticamente incomum não corresponde, por si só, a fraude ou irregularidade. O problema é, portanto, construir uma triagem que reduza o universo de análise sem perder a contextualização necessária para interpretar os desvios.

Pergunta de pesquisa. Em que medida uma arquitetura analítica baseada em segmentação por porte operacional, indicadores estatísticos e detecção não supervisionada pode reduzir e contextualizar o universo de ocorrências priorizadas, em comparação com regras globais simples aplicadas à base transacional do SEE?

Objetivo geral. Desenvolver e avaliar uma Prova de Conceito computacional, auditável e rastreável, para identificação e priorização de padrões operacionais potencialmente atípicos, avaliando sua seletividade, contextualização por porte e comportamento em relação a uma baseline de regras globais.

Para alcançar esse objetivo, o estudo caracteriza a base e sua qualidade, define a unidade observacional Serventia $\times$ Mês, transforma o volume operacional, segmenta as observações em faixas de porte, aplica Z-Score e Isolation Forest, compara a quantidade e a sobreposição dos alertas com uma baseline global por percentis, examina a sensibilidade dos parâmetros e documenta a arquitetura de disponibilização dos resultados em painéis gerenciais.

Hipótese. Uma arquitetura baseada na segmentação por porte operacional e na combinação entre Z-Score e Isolation Forest produzirá um conjunto mais seletivo e contextualizado de ocorrências potencialmente atípicas do que uma abordagem baseada em regras globais, preservando rastreabilidade para eventual análise institucional posterior.

2 FUNDAMENTAÇÃO ESSENCIAL

2.1 CIÊNCIA DE DADOS E APOIO ANALÍTICO NO SETOR PÚBLICO

O uso de ciência de dados no setor público integra iniciativas de modernização da gestão e de apoio à tomada de decisão baseada em evidências. No Poder Judiciário, a consolidação de infraestruturas de dados e de mecanismos analíticos é incentivada pela ENTIC-JUD. Bontempo et al. (2024) descrevem o uso de Business Intelligence no TJGO para apoiar o acompanhamento de indicadores institucionais, evidenciando a relevância de soluções que organizem informação para gestores e áreas finalísticas.

2.2 FISCALIZAÇÃO ORIENTADA A DADOS

A literatura de auditoria descreve a evolução de práticas amostrais para abordagens que utilizam processamento eletrônico de dados e monitoramento mais sistemático (ARENS; ELDER; BEASLEY, 2014; SILVA, 2012). Neste trabalho, essa referência é utilizada como motivação para a construção de uma camada analítica de triagem. A PoC não implementa auditoria contínua em produção nem substitui procedimentos correccionais; ela organiza dados históricos e produz ocorrências potencialmente atípicas para eventual exame humano.

2.3 CRISP-DM E TÉCNICAS EMPREGADAS

O CRISP-DM organiza projetos de mineração de dados em etapas de entendimento do negócio, entendimento e preparação dos dados, modelagem, avaliação e implantação (CHAPMAN et al., 2000). Neste estudo, o CRISP-DM é utilizado como framework operacional do processo de ciência de dados; o desenho científico, por sua vez, é um estudo de caso quantitativo e aplicado que compara estratégias de triagem sobre uma série histórica institucional.

O K-Means foi empregado para formar faixas de porte operacional a partir do volume mensal transformado, evitando comparação direta entre observações de escalas muito distintas (VANDERPLAS, 2016). O Z-Score foi utilizado como medida relativa de afastamento da taxa de cancelamento dentro de cada faixa de porte, sem interpretação probabilística baseada em normalidade, pois a distribuição apresenta forte concentração em zero (MORETTIN; BUSSAB, 2017). O Isolation Forest complementa a análise ao identificar combinações pouco frequentes entre volume e taxa de cancelamento em um espaço de duas variáveis (LIU; TING; ZHOU, 2008).

3 MÉTODO

3.1 DESENHO DO ESTUDO E BASE DE DADOS

A pesquisa caracteriza-se como aplicada, quantitativa, retrospectiva e desenvolvida na forma de estudo de caso institucional. O objeto técnico é uma Prova de Conceito analítica construída sobre dados do SEE/TJGO. A avaliação final concentra-se em propriedades internas e comparativas da arquitetura — seletividade, contextualização por porte, rastreabilidade, sensibilidade e estabilidade — e não inclui validação externa por especialistas. Consequentemente, o estudo não mede relevância correcional, precisão ou taxa de falsos positivos dos alertas.

A série histórica compreende janeiro de 2016 a julho de 2025, totalizando 115 meses. A extração inicial produziu 76.862 observações agregadas na granularidade Serventia × Mês. Após a aplicação do recorte temporal, foram removidas 19.382 observações situadas fora da janela definida, resultando em 57.480 observações referentes a 524 serventias. Das 553 serventias identificadas na extração original, 29 possuíam registros apenas entre 2013 e 2015 e, por isso, ficaram fora da população analisada.

Tabela 3.1. Caracterização do universo analítico

Indicador	Resultado
Período analisado	jan./2016 a jul./2025 (115 meses)
Observações na extração inicial	76.862
Observações removidas pelo recorte temporal	19.382
Base analítica final	57.480 observações Serventia × Mês
Serventias na base final	524
Serventias excluídas integralmente	29 (registros apenas entre 2013 e 2015)

Fonte: elaborado pelo autor (2026).

3.2 QUALIDADE DOS DADOS E ENGENHARIA DE VARIÁVEIS

Durante o entendimento dos dados, o campo `guia_id` foi investigado como possível elo entre os atos e sua dimensão financeira. Foram observadas concentrações e associações temporais que impediram estabelecer correspondência individual confiável entre utilização do selo, emissão de guia e pagamento. Assim, `guia_id` e variáveis derivadas de ausência de guia foram excluídos da modelagem, evitando inferências financeiras não sustentadas pelos dados disponíveis.

A modelagem foi baseada no volume mensal de selos e em um indicador operacional de inutilização/cancelamento. O volume apresentou forte assimetria positiva, com média de

4.014,71 selos por observação, mediana de 1.121 e máximo de 267.645. Por isso, foi aplicada a transformação $\log_{1p}$, gerando `log_total_selos`. A `taxa_cancelamento` foi calculada como a razão entre `total_cancelados` e `total_selos` e apresenta média de 0,15%, mediana de 0% e máximo de 78,43%.

Existe, contudo, uma limitação semântica relevante no campo inutilizado da tabela transacional: os registros históricos incluem valores TRUE, FALSE e NULL. Embora os valores nulos não sejam convertidos automaticamente em FALSE na etapa de qualidade, o denominador de `taxa_cancelamento` utiliza `total_selos` e, portanto, inclui observações cuja situação de inutilização não está explicitamente preenchida. Como a semântica de NULL não foi confirmada nesta pesquisa, a taxa é tratada como indicador operacional da PoC, e não como medida definitiva de cancelamento. Esse ponto é retomado nas limitações.

Tabela 3.2. Variáveis centrais da Prova de Conceito

Variável	Definição e papel
<code>cartorio_id</code>	Identificador da serventia; usado somente para rastreabilidade.
<code>mes</code>	Competência mensal; compõe a unidade observacional.
<code>total_selos</code>	Contagem mensal de registros; representa o volume operacional.
<code>taxa_cancelamento</code>	<code>total_cancelados / total_selos</code> ; indicador proporcional usado no Z-Score e no Isolation Forest.
<code>log_total_selos</code>	$\log_{1p}(\text{total_selos})$; variável usada para segmentar as observações por porte.
<code>cluster_par</code>	Faixa de porte operacional atribuída pelo K-Means.
<code>z_score_par</code>	Afastamento da taxa de cancelamento em relação à média da faixa de porte.
<code>iforest_score</code>	Classificação anômala/normal do Isolation Forest.
<code>score_prioridade</code>	Regra heurística para ordenar alertas; não representa probabilidade de irregularidade.

Fonte: elaborado pelo autor (2026).

3.3 ARQUITETURA ANALÍTICA E BASELINE

A arquitetura possui três etapas analíticas principais. Primeiro, `log_total_selos` é padronizada e utilizada no K-Means para formar quatro faixas de porte operacional. Em seguida, o Z-Score é calculado sobre `taxa_cancelamento` dentro de cada faixa, com análise unilateral direcionada a valores superiores à média. Valores $Z > 2$ são tratados como afastamentos relevantes e $Z > 3$ como afastamentos elevados, sem atribuição de probabilidade normal a esses limiares. Paralelamente, o Isolation Forest é aplicado a `log_total_selos` e `taxa_cancelamento`, com `n_estimators = 200`, `random_state = 42` e `contamination = 1%` no modelo final.

Os dois componentes são consolidados em uma regra de priorização. Uma observação é classificada como Risco Crítico quando apresenta $Z > 3$ e é anômala pelo Isolation Forest; como Alerta Moderado quando $Z > 2$ sem atender à condição anterior; como Alerta Multivariado quando $Z \leq 2$ e o Isolation Forest a classifica como anômala; e como Normal quando nenhuma dessas condições ocorre. O Score de Prioridade é calculado como $Score = \max(Z, 0) + I$, em que I vale 1 para anomalia do Isolation Forest e 0 caso contrário. Trata-se de uma regra operacional heurística e transparente, não de um escore probabilístico. A expressão “Risco Crítico” é utilizada exclusivamente como categoria metodológica de priorização e não representa risco jurídico, administrativo ou irregularidade confirmada.

Para comparação, foi definida uma baseline global por percentis composta por duas regras globais: volume mensal de selos acima do percentil 95 ou taxa de cancelamento acima do percentil 90. A baseline representa um filtro simples e determinístico que não considera porte operacional nem relações conjuntas entre variáveis.

3.4 ESTRATÉGIA DE AVALIAÇÃO

A avaliação do K-Means considerou k entre 2 e 6, usando inércia, coeficiente Silhouette e índice Davies-Bouldin, além da interpretabilidade das faixas. A sensibilidade do Isolation Forest foi examinada com contamination de 1%, 3% e 5%. Para o componente univariado, tentou-se um Z-Score robusto baseado em MAD; porém, a inflação de zeros produziu mediana e MAD iguais a zero em todas as faixas. Como alternativa, os alertas por Z-Score foram confrontados com percentis internos às faixas de porte. A estabilidade temporal das faixas também foi descrita por meio da persistência das serventias em meses consecutivos.

Não existe ground truth de irregularidade e não foi realizada validação humana dos alertas. Por isso, a comparação com a baseline é interpretada exclusivamente em termos de seletividade e estrutura da priorização. Menor quantidade de alertas não é tratada como evidência de maior precisão ou eficácia fiscalizatória.

4 RESULTADOS

4.1 SEGMENTAÇÃO POR PORTE OPERACIONAL

Entre as configurações avaliadas, $k = 4$ foi adotado como compromisso entre compactação estatística e interpretabilidade operacional. Embora $k = 3$ tenha apresentado o maior coeficiente Silhouette, $k = 4$ produziu quatro faixas de volume diretamente interpretáveis e evitou grupos residuais muito pequenos.

Tabela 4.1. Métricas utilizadas na seleção do número de faixas de porte

k	Inércia	Silhouette	Davies-Bouldin	Menor / maior cluster
2	24.570,01	0,5135	0,6619	27.431 / 30.049
3	11.558,33	0,5640	0,5305	6.277 / 32.063
4	6.928,91	0,5341	0,5301	5.333 / 23.129
5	4.492,07	0,5392	0,5229	4.619 / 19.474
6	3.362,64	0,5226	0,5264	3.269 / 15.760

Fonte: elaborado pelo autor (2026).

Tabela 4.2. Caracterização das quatro faixas de porte operacional

Faixa	Observações	% da base	Volume mínimo	Volume máximo
Muito pequeno	5.333	9,28%	1	140
Pequeno	23.129	40,24%	141	1.103
Médio	20.096	34,96%	1.104	5.630
Grande	8.922	15,52%	5.632	267.645

Fonte: elaborado pelo autor (2026).

As faixas representam condições mensais de porte, e não categorias permanentes das serventias. Uma mesma serventia pode transitar entre faixas ao longo da série conforme seu volume operacional se altera.




Figura 4.1. Distribuição das observações segundo as faixas de porte operacional. A taxa exibida no eixo vertical possui função descritiva; a formação das faixas pelo K-Means utilizou exclusivamente `log_total_selos`.

Fonte: elaborado pelo autor (2026).

4.2 SELETIVIDADE DA ARQUITETURA HÍBRIDA

A baseline global por percentis selecionou 8.166 observações, equivalentes a 14,21% da base. O Z-Score por faixa sinalizou 726 observações (1,26%), o Isolation Forest classificou 575 observações como anômalas (1,00%) e a regra híbrida consolidou 790 alertas (1,37%). Em relação à baseline, a PoC reduziu o universo priorizado em aproximadamente 90,3%. Esse resultado demonstra maior seletividade operacional, não maior acurácia.

Tabela 4.3. Seletividade das estratégias analíticas

Estratégia	Alertas	% da base
Baseline global por percentis	8.166	14,21%
Z-Score por faixa ($Z > 2$)	726	1,26%
Isolation Forest (1%)	575	1,00%
Arquitetura híbrida	790	1,37%

Fonte: elaborado pelo autor (2026).

A interseção entre Z-Score e Isolation Forest reuniu 511 observações. Destas, 377 também apresentaram $Z > 3$ e foram classificadas como Risco Crítico. Outras 349 observações foram classificadas como Alerta Moderado e 64 foram identificadas exclusivamente pelo componente multivariado, sem ultrapassar $Z > 2$. Esse último grupo evidencia complementaridade entre os mecanismos, ainda que ambos utilizem a taxa de cancelamento em sua construção.

Tabela 4.4. Distribuição dos alertas da arquitetura híbrida

Classificação final	Quantidade
Risco Crítico	377
Alerta Moderado	349
Alerta Multivariado	64
Total de alertas	790

Fonte: elaborado pelo autor (2026).

4.3 SENSIBILIDADE E ESTABILIDADE

O aumento de contamination de 1% para 3% e 5% elevou a quantidade de observações classificadas como anômalas pelo Isolation Forest e, consequentemente, o volume final de alertas. A configuração de 1% foi mantida por representar uma decisão operacional conservadora de triagem, não um ótimo estatístico. Os 575 alertas identificados em 1% permaneceram contidos nas configurações mais amplas de 3% e 5%, indicando estabilidade do subconjunto mais restrito.

Tabela 4.5. Sensibilidade ao parâmetro contamination

contamination	Alertas IF	Alertas híbridos	Riscos críticos
1%	575	790	377
3%	1.725	1.725	408
5%	2.874	2.874	408

Fonte: elaborado pelo autor (2026).

A análise complementar do Z-Score mostrou que as 726 observações com $Z > 2$ estão acima do percentil 97,5 de taxa de cancelamento de suas respectivas faixas de porte; 577 delas, equivalentes a 79,48% dos alertas do Z-Score, superam o percentil 99. Esse resultado reforça que os alertas univariados se concentram na cauda extrema da distribuição, embora não elimine as limitações decorrentes da assimetria e da inflação de zeros.

A persistência mediana das serventias em faixas de porte em meses consecutivos foi de 95,61%, e a média foi de 90,39%. Isso indica que as faixas são predominantemente estáveis, mas não permanentes. Essa análise descreve a consistência temporal da segmentação; ela não substitui um backtesting com separação entre treinamento e teste.

4.4 PRODUTOS DA PROVA DE CONCEITO

Além do pipeline analítico em Python e da tabela ordenada de alertas, foram desenvolvidos painéis em Power BI para organizar a consulta aos resultados. A camada de visualização contempla uma visão geral dos alertas, uma relação de casos priorizados pelo Score de Prioridade

e um perfil temporal de cada serventia. Esses painéis materializam a rastreabilidade da PoC e demonstram como os resultados podem ser disponibilizados para análise institucional, sem automatizar decisões ou substituir procedimentos correccionais.



Figura 4.2. Painel gerencial desenvolvido para exploração dos resultados da Prova de Conceito.

Fonte: elaborado pelo autor (2026).

A arquitetura conceitual de eventual integração ao SEE prevê extração em ambiente somente leitura, processamento do pipeline, armazenamento das ocorrências priorizadas, disponibilização em painel e revisão humana antes de qualquer consequência administrativa. Essa revisão é requisito de governança para uma possível etapa futura e não foi executada como componente de avaliação deste estudo.

5 DISCUSSÃO

A pergunta de pesquisa buscou verificar em que medida uma arquitetura híbrida poderia reduzir e contextualizar o universo de ocorrências priorizadas em comparação com regras globais simples. Os resultados sustentam essa proposição em três dimensões: seletividade, contextualização e rastreabilidade.

Primeiro, a arquitetura híbrida reduziu de 8.166 para 790 o número de observações selecionadas, correspondendo a aproximadamente 90,3% de redução no universo priorizado frente à baseline. O ganho demonstrado é, portanto, de seletividade. Sem rótulos ou validação externa, não é possível afirmar que essa redução corresponda a maior precisão, menor taxa de falsos positivos ou maior eficácia da fiscalização. Essa diferença também depende dos limiares adotados na baseline, dos cortes de Z-Score e do valor de contamination definido para o Isolation Forest. Portanto, a redução observada caracteriza a seletividade obtida sob as parametrizações escolhidas e não representa superioridade intrínseca da arquitetura.

Segundo, a segmentação por porte operacional evita que observações de escalas muito distintas sejam comparadas diretamente. Como o K-Means utiliza apenas `log_total_selos`, os grupos devem ser interpretados estritamente como faixas de volume e não como pares completos em termos de município, especialidade ou natureza dos atos. Ainda assim, essa segmentação fornece contexto operacional adicional em relação à baseline global.

Terceiro, a combinação entre Z-Score e Isolation Forest torna explícitos os elementos que contribuíram para cada sinalização. O Z-Score informa o afastamento da taxa dentro da faixa de porte; o Isolation Forest identifica combinações pouco frequentes de volume e taxa; e o Score de Prioridade organiza os casos de forma reproduzível. Essa rastreabilidade é relevante para ambientes institucionais em que o resultado analítico precisa ser explicado e revisado antes de qualquer decisão.

A análise de sensibilidade também contribui para compreender o comportamento da PoC. O parâmetro contamination controla diretamente o volume de casos sinalizados pelo Isolation Forest, enquanto a comparação com percentis mostra que os alertas do Z-Score se concentram na cauda extrema das respectivas faixas. Esses resultados não definem um parâmetro “ótimo”, mas tornam explícito o efeito das escolhas metodológicas sobre a carga de triagem.

Como ilustração do funcionamento da arquitetura, os casos originalmente selecionados no relatório técnico evidenciam mecanismos distintos de sinalização: convergência entre Z-Score e Isolation Forest, alerta univariado moderado e alerta apenas multivariado. Esses exemplos servem para explicar o comportamento da regra híbrida, mas não constituem validação de relevância correccional, pois não foram submetidos a julgamento especializado.

A contribuição aplicada do estudo, portanto, não reside na proposição de novos algoritmos, mas na construção de uma arquitetura auditável que conecta engenharia de dados, segmentação de porte, indicadores de afastamento, detecção não supervisionada, priorização e visualização.

Para o TJGO, essa PoC demonstra uma forma de converter a série histórica do SEE em um conjunto reduzido e rastreável de ocorrências que podem ser submetidas, em etapa posterior, à avaliação institucional.

6 LIMITAÇÕES E GOVERNANÇA

A principal limitação do estudo é a ausência de ground truth e de validação externa por especialistas. Assim, os resultados permitem avaliar seletividade, estrutura interna e comportamento comparativo da arquitetura, mas não a correção, relevância correcional ou eficácia dos alertas. A existência de comportamento estatisticamente atípico não deve ser interpretada como fraude, irregularidade ou descumprimento normativo.

Uma segunda limitação está na semântica do campo inutilizado. O conjunto transacional possui registros TRUE, FALSE e NULL, e a taxa utilizada no estudo tem total_selos como denominador. A semântica histórica dos valores NULL não foi confirmada nesta pesquisa; por essa razão, a taxa utilizada deve ser interpretada como indicador operacional de inutilização/cancelamento da PoC. Essa limitação deve ser considerada na leitura dos resultados, especialmente porque taxa_cancelamento participa tanto do Z-Score quanto do Isolation Forest.

Também permanecem limitações decorrentes do uso de apenas duas variáveis no componente multivariado, da natureza heurística do Score de Prioridade, da inexistência de backtesting temporal completo e da segmentação baseada apenas em volume operacional. Além disso, a escolha de k , dos limiares de Z-Score e de contamination foi realizada no contexto desta PoC e precisaria ser reavaliada diante de novos dados ou de requisitos operacionais específicos.

Foi estruturado no relatório técnico um protocolo de 30 casos para eventual avaliação institucional futura, contemplando alertas críticos, moderados, multivariados e observações sem alerta. Esse protocolo não foi executado e, por isso, não integra a evidência empírica deste artigo. Seu papel é registrar um caminho de continuidade para a solução caso a instituição decida avançar da PoC para um piloto controlado.

7 CONCLUSÃO

Este trabalho desenvolveu e avaliou uma Prova de Conceito para triagem de ocorrências potencialmente atípicas em dados históricos do Sistema Extrajudicial Eletrônico do TJGO. A arquitetura combinou segmentação por porte operacional, Z-Score por faixa, Isolation Forest e uma regra rastreável de priorização.

Os resultados oferecem suporte à hipótese no que se refere à seletividade e à contextualização. A baseline global selecionou 8.166 observações, enquanto a arquitetura híbrida priorizou 790, reduzindo o universo de análise em aproximadamente 90,3%. A segmentação por porte adicionou contexto às comparações e a combinação dos métodos produziu categorias distintas de sinalização, incluindo 64 ocorrências identificadas apenas pelo componente multivariado.

Esses achados não permitem concluir que os 790 alertas sejam mais corretos, mais relevantes para a fiscalização ou representem irregularidades. A ausência de ground truth e de validação humana restringe a conclusão à capacidade da PoC de produzir uma seleção menor, contextualizada e rastreável em comparação com regras globais simples.

Como entregas aplicadas, o estudo disponibiliza um pipeline analítico reproduzível, regras explícitas de priorização e painéis gerenciais para exploração dos resultados. A semântica histórica dos valores NULL do campo inutilizado permanece como limitação metodológica declarada. Caso haja interesse institucional na continuidade da solução, etapas futuras poderão incluir validação institucional dos alertas e avaliação da arquitetura em cenário temporal prospectivo antes de eventual uso operacional.

REFERÊNCIAS BIBLIOGRÁFICAS

- ARENS, A. A.; ELDER, R. J.; BEASLEY, M. S. *Auditing and Assurance Services: An Integrated Approach*. 15. ed. Boston: Pearson, 2014.
- BONTEMPO, Paulo Cesar et al. Utilização de Business Intelligence no cumprimento de metas nacionais do Poder Judiciário no Tribunal de Justiça do Estado de Goiás. *Interfaces Científicas - Direito*, v. 9, n. 3, p. 108–124, 2024.
- BRASIL. Conselho Nacional de Justiça. Resolução nº 370, de 28 de janeiro de 2021. Estabelece a Estratégia Nacional de Tecnologia da Informação e Comunicação do Poder Judiciário (ENTIC-JUD). Brasília, DF: CNJ, 2021.
- CHAPMAN, P. et al. *CRISP-DM 1.0: step-by-step data mining guide*. SPSS Inc., 2000.
- LIU, F. T.; TING, K. M.; ZHOU, Z.-H. Isolation forest. In: *2008 Eighth IEEE International Conference on Data Mining*. Pisa: IEEE, 2008. p. 413–422.
- MORETTIN, Pedro Alberto; BUSSAB, Wilton de Oliveira. *Estatística básica*. 9. ed. São Paulo: Saraiva, 2017.
- SILVA, Washington Lopes da. *Auditoria contínua de dados como instrumento de automação do controle empresarial*. 2012. Tese (Doutorado em Ciências) – Escola Politécnica, Universidade de São Paulo, São Paulo, 2012.
- VANDERPLAS, J. *Python Data Science Handbook: Essential Tools for Working with Data*. Sebastopol, CA: O'Reilly Media, 2016.